

Veri Madenciliđi Yöntemleriyle Makroekonomik Göstergelerin Bitcoin Fiyat Tahminlemesi Üzerindeki Etkisinin Analizi


2025–2026GüzDönemi · VeriMadenciliđi · FinalProjesi

Grup : MacroMinds

YouTube Link: <https://youtu.be/RM2oZP8zNvE?si=7Ys9VEpKpbFId76>

GitHub Reposu: <https://github.com/murat-khabibullayev/Btc-Prediction-Project/tree/main>

Bu proje, Bitcoin'in fiyat hareketlerini makroekonomik göstergeler ve gelişmiş makine öğrenimi modelleri kullanarak tahmin etmeyi amaçlamaktadır.



Motivasyon ve Araştırma Soruları

Neden Bu Problem?

- **Yüksek Volatilité:**Bitcoin fiyatları kısa sürede seretdalgalanır.
- **Makroekonomik Etki:** Bitcoin artık ABD faizleri, enflasyon ve dolar endeksi gibi göstergelerle daha bağlantılı.
- **Karar Desteęi:** Daha bilinçli analizler, yatırım ve risk yönetimi için önemlidir.

Araştırma Soruları

- Makroekonomik göstergeler Bitcoin tahmin performansını gerçekten iyileştiriyor mu?
- Farklı model aileleri, farklı zaman ufuklarında nasıl davranıyor?
- Kriz ve ayı piyasası dönemlerinde modeller ne kadar dayanıklı?



Veri Seti Tanımı

Veri Kaynakları

- **Yahoo Finance:** BTC-USD tarihsel fiyat verileri
- **FRED:** 17 makroekonomik gösterge (Faiz, enflasyon, dolar endeksi, volatilité, işsizlik vb.)

Veri Yapısı

- **Özellikler:** Finansal + Makroekonomik
- **Tür:** Sayısal veriler ve zaman damgaları
- **Boyut:** 4067 gözlem, 120+ özellik

Hedef Değişkenler

- 1 gün, 7 gün, 30 gün ve 365 gün sonrası
- Bitcoin kapanış fiyatı (USD)

Target_1d

Mevcut günden 1 gün sonraki BTC kapanış fiyatı.

Target_7d

Mevcut günden 7 gün sonraki BTC kapanış fiyatı.

Target_30d

Mevcut günden 30 gün sonraki BTC kapanış fiyatı.

Target_365d

Mevcut günden 365 gün sonraki BTC kapanış fiyatı.

Veri Hazırlama ve Bölme Stratejisi

Veri Ön İşleme

- Hatalı hacim değerleri ve tarih çakışmaları temizlendi
- Eksik veriler zaman serisine uygun şekilde **forward fill** ile tamamlandı

Ölçekleme ve Dönüşümler

- **Deep Learning:** MinMaxScaler (0–1)
- **Ensemble Modeller:** StandardScaler
- Fiyat seviyeleri yerine **logaritmik getiriler** kullanıldı

Özellik Mühendisliği

- **Gecikmeli Özellikler (Lag Features):**
1, 7, 30 ve 365 günlük geçmiş fiyat bilgileri

Zaman Serisi Bölme

- 2022-01-01 öncesi: **Eğitim seti**
- 2022-01-01 sonrası: **Test seti**
- Veri sızıntısını önlemek için kronolojik bölme

Kullanılan Modeller

Ensemble Learning

- RandomForest
- Gradient Boosting / HistGradientBoosting
- ExtraTrees
- AdaBoost
- XGBoost

Derin Öğrenme

- LSTM
- GRU
- MLP

Model Yaklaşımı

- Farklı model aileleri karşılaştırılarak **hangi yaklaşımın hangi zaman ufkunda daha başarılı olduğu** analiz edildi.

Hiperparametre Optimizasyonu

Amaç

- Overfitting'i azaltmak
- Modelleri adil ve karşılaştırılabilir hale getirmek

Kullanılan Yöntemler

- **RandomizedSearchCV**: Geniş aralıkta hızlı deneme
- **GridSearchCV**: Seçilen dar aralıkta ince ayar

Ayarlanan Temel Parametreler

- `n_estimators`: Ağaç sayısı
- `max_depth`: Model karmaşıklığı
- `learning_rate`: Boosting modelleri için öğrenme hızı
- `subsample`: Veri oranı (Boosting)

Derin Öğrenme

- Katman sayısı ve nöron sayıları
- **Early Stopping** ile aşırı öğrenme kontrolü

Aşırı Öğrenmeyi Önleme

- Erken Durdurma (Early Stopping): LSTM ve Gradient Boosting modellerinde doğrulama kaybı (validation loss) iyileşmediğinde eğitim durdurulmuştur.

Değerlendirme Tasarımı



Kullanılan Metrikler

- **R^2** : Modelin fiyathareketini ne kadar açıkladığı
- **RMSE**: Büyük hatalara duyarlı hata metriği
- **MAE**: Ortalama mutlak hata
- **MAPE (%)**: Yüzdesel hata (yorumlanması en kolay metrik)



Doğrulama Yaklaşımı

- **Zaman serisi bazlı bölme**
- Eğitim: 2022 öncesi
- Test: 2022 sonrası (yüksek volatilité dönemi)



Analiz

- Gerçek vs Tahmin grafikleri
- Yüksek volatilité dönemlerine özel hata incelemesi

Sonuçlar: Model Performans Analizi

Target_1d (1 Günlük Tahmin)

Model	RMSE	MAE	R ²	MAPE (%)
RandomForest	2268.98	1612.70	0.9828	3.61
GradientBoosting	2948.22	1867.25	0.9710	3.60 4.28
HistGradientBoosting	3027.36	1997.00	0.9719	
AdaBoost				
ExtraTrees	2948.48	2074.09	0.9733	4.75
XGBoost	4861.92	3894.55	0.9212	8.35
LSTM	6982.26	5303.07	0.8375	10.33
GRU	26687.65	23579.43	-1.45	49.48
MLP	26723.21	21572.19	-1.46	40.94
SVR	29680.37	22948.49	-1.93	42.71
	36440.40	31953.35	-3.42	67.99

Target_7d (7 Günlük Tahmin)

Model	RMSE	MAE	R ²	MAPE (%)
AdaBoost	5793.49	4299.66	0.8984	9.67
HistGradientBoosting RandomForest	6875.35	5639.69	0.8570	13.40
GradientBoosting	7334.32	6022.05	0.8224	13.12
ExtraTrees	8973.33	6618.09	0.7342	12.59
XGBoost	11497.30	10023.75	0.5637	21.69
MLP	11927.13	10561.69	0.5304	23.60
SVR	40167.55	33936.25	-4.32	68.55
	36886.60	32418.43	-3.49	68.33


Target_30d (30 Günlük Tahmin)

Model	RMSE	MAE	R ²	MAPE (%)
AdaBoost	15584.79	11808.19	0.3757	23.11


Target_365d (365 Günlük Tahmin)

Model	RMSE	MAE	R ²	MAPE (%)
GradientBoosting	43329.54	36749.36	-2.60	39.36


RandomForest | Target_1d - Real vs Pred (test)




AdaBoost - Target_7d (Real vs Pred)



AdaBoost - Target_30d (Real vs Pred)



GradientBoosting | Target_365d - Real vs Pred (test)



Genel Sonuç ve Öneriler

Genel Sonuçlar

- Bu çalışmada, **Ensemble Learning yöntemlerinin**, makroekonomik göstergelerle birlikte kullanıldığında **kısa vadeli Bitcoin fiyat tahminlerinde (1–7 gün)** yüksek doğruluk sağladığı gösterilmiştir.
- **Gecikmeli özellikler (Lag Features)** ile **DXY, S&P 500 ve VIX** gibi makroekonomik değişkenlerin, model performansını anlamlı düzeyde artırdığı gözlemlenmiştir.
- **2022–2024 yüksek volatilité dönemleri** dikkate alındığında, **AdaBoost ve RandomForest** modellerinin piyasa dalgalanmalarına karşı daha **istikrarlı ve dayanıklı** sonuçlar ürettiği görülmüştür.

Gelecek Çalışmalar planı

- **Veri Setinin Genişletilmesi:** Daha uzun zaman aralıkları ve ek finansal göstergelerle derin öğrenme modellerinin performansı artırılabilir.
- **Duygu Analizi Entegrasyonu:** Sosyal medya ve haber verilerinden elde edilecek duygu skorları, kısa vadeli fiyat hareketlerini daha iyi yakalamaya yardımcı olabilir.
- **Adaptif Öğrenme Yaklaşımları:** Piyasa koşullarına göre kendini güncelleyen dinamik modeller gelecekte incelenebilir.
- **Farklı Kripto Varlıklar:** Yöntem, Ethereum gibi diğer büyük kripto paralar üzerinde uygulanarak genellenebilirliği test edilebilir.

Dinlediğiniz için teşekkürler!

Kaynaklar

Bu çalışma boyunca faydalanılan temel akademik yayınlar ve referanslar aşağıda listelenmiştir:

- Brown, G., & Mues, C. (2012). An empirical comparison of classification models for credit scoring. Expert Systems with Applications, 39(11), 11440-11447. (Ensemble öğrenme yöntemleri üzerine genel referans)
- McNally, S., Roche, J., & Caton, S. (2018). Predicting the price of Bitcoin using machine learning. 2018 International Conference on Engineering Applications of Neural Networks (EANN), 131-140. (Bitcoin fiyat tahminlemesi üzerine özel çalışma)
- Kim, H. Y. (2019). Predicting the direction of stock index movement using a hybrid CNN-LSTM model. Decision Support Systems, 118, 22-30. (Derin öğrenme modellerinin finansal zaman serilerinde kullanımı)
- Gündüz, A., & Sarıkaya, M. (2020). Makroekonomik değişkenlerin kripto para piyasaları üzerindeki etkisi. Uluslararası İktisadi ve İdari Bilimler Dergisi, 4(1), 77-90. (Makroekonomik göstergelerin kripto piyasası etkisi)
- Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32. (Random Forest algoritmasının orijinal yayını)

GitHub Reposu: <https://github.com/murat-khabibullayev/Btc-Prediction-Project/tree/main>