

VERİ MADENCİLİĞİ PROJESİ

Grubun Adı : MacroMinds

Dönem: 2025/2026 Güz Dönem **Sınav Türü :** Final Sınavı

Proje Bilgileri : Veri Madenciliği Yöntemleriyle Makroekonomik
Göstergelerin Bitcoin Fiyat Tahminlemesi Üzerindeki Etkisinin Analizi

Öğrenci Bilgileri

Adı	Soyadı	Öğrenci Numarası	Mail Adress
Abdumajid	Abdulkhaev	22040101002	abdumajidabdulkhaev@stu.topkapi.edu.tr
Khaiitmurod	Khabibullayev	22040101116	khaiitmurodkhabibul1@stu.topkapi.edu.tr
Diyorjon	Ochilov	22040101139	diyorjonochilov@stu.topkapi.edu.tr
Yesset	Yelebayev	22040101123	yessetyelebayev@stu.topkapi.edu.tr
İbrahim Halil	Yanaç	22040101043	ibrahimhalilyanac@stu.topkapi.edu.tr

2) Problem Tanımı

- **İş/Bilimsel Soru:** Projenin temel amacı, Bitcoin'in (BTC-USD) gelecekteki fiyat hareketlerini (1, 7, 30 ve 365 gün) sadece tarihsel fiyatlarla değil; ABD Faiz Oranları, Enflasyon (CPI), Dolar Endeksi (DXY) gibi makroekonomik verilerle tahmin etmektir. Final aşamasında vize sonuçlarının üzerine çıkmak için **Ensemble Learning (XGBoost, RandomForest, AdaBoost)** ve **Deep Learning (LSTM, GRU)** mimarileri kullanılmıştır.
- **Görev Türü:** Zaman Serisi Regresyonu.
- **Paydaş Değeri (Stakeholder Value):** Bu çalışma, bireysel yatırımcılar ve risk yönetimi fonları için, volatil piyasalarda makroekonomik sinyalleri kullanarak riskten korunma (hedging) ve portföy optimizasyonu sağlama potansiyeline sahiptir.
- **Hedef Değişken(ler):** Çalışmada, farklı yatırım ufuklarını analiz etmek amacıyla dört ayrı hedef değişken tanımlanmıştır. Hepsinin birimi ABD Doları (USD) cinsinden Bitcoin kapanış fiyatıdır.
 - **Target_1d:** Mevcut günden 1 gün sonraki BTC kapanış fiyatı.
 - **Target_7d:** Mevcut günden 7 gün sonraki BTC kapanış fiyatı.
 - **Target_30d:** Mevcut günden 30 gün sonraki BTC kapanış fiyatı.
 - **Target_365d:** Mevcut günden 365 gün sonraki BTC kapanış fiyatı.
- **Başarı Kriterleri:**

Kısa vadede (1-7 gün) $R^2 \geq 0.90$ ve MAPE $\leq$ %5 hata payına ulaşmak; 30-365 günlük tahminlerde ise baz modellerden (Baseline) daha iyi RMSE değerleri elde etmek.

3) Proje Yönetimi

Kilometre Taşları:

Proje süreci, veri toplama aşamasından ileri seviye modelleme ve nihai raporlamaya kadar 7 haftalık bir takvime yayılmıştır:

- **1. Hafta:** Veri seti (Yahoo Finance & FRED) ve proje konusu seçimi. Problem tanımının yapılması ve iş akışının belirlenmesi.

- **2. Hafta:** 17 farklı veri kaynağının birleştirilmesi. Veri Ön İşleme, Eksik Veri Yönetimi (Imputation) ve EDA (Keşifsel Veri Analizi) çalışmalarının tamamlanması.
- **3. Hafta:** Temel Model (Base Model) Geliştirme. Linear Regression, Ridge, KNN ve Decision Tree modelleriyle vize aşaması testlerinin yapılması.
- **4-5. Haftalar:** Gelişmiş Model Ailelerinin Geliştirilmesi (Ensemble & Deep Learning). Hiper-parametre Optimizasyonu (GridSearch/RandomSearch) ve özellik mühendisliği (Lag features).
- **6. Hafta:** Performans Analizi ve Değerlendirmesi. RMSE, MAE, Rve MAPE metriklerinin hesaplanması, modellerin karşılaştırılması.
- **7. Hafta:** Final proje raporunun son halinin verilmesi, görselleştirmelerin (Real vs Pred plots) tamamlanması ve sunumun oluşturulması.
- **Final Dönemi:** merged_with_lags.csv üzerinden gecikmeli özniteliklerin (lag features) eklenmesi, Ensemble (XGBoost, RandomForest, AdaBoost) ve Deep Learning (LSTM, GRU) modellerinin eğitilmesi.
- **Çıktılar:** Proje sonunda üretilecek çıktılar şunlardır:
 - **GitHub Repo Linki:** <https://github.com/murat-khabibullayev/Bitcoin-Price-Prediction-Project/tree/main>
 - **İşlenmiş Veri (Processed Data):** Tüm ham verilerin tarih bazlı birleştirilmesi, temizlenmesi ve özellik mühendisliği işlemlerinden geçirilmesiyle oluşturulan, model eğitiminde kullanılan nihai dosya: **merged_data.csv** (4067 Satır, 73 Sütun).
 - **Jupyter Notebook Dosyaları:** Her üyenin kendi gelişmiş modellerini içeren kodlar.
 - **Veri & Veri Sözlüğü:** Ham veriler, merged_with_lags.csv dosyası ve özellik açıklamaları.

Roller ve Sorumluluklar: Her üye en az 2 gelişmiş modelin (Advanced Models) hiper-parametre ayarlamasından (GridSearch/RandomSearch), eğitiminden ve görselleştirmesinden sorumlu olmuştur.

Üye Adı	Öğrenci No	Sorumlu Olduğu Modeller	Diğer Sorumluluklar
Khaiitmurod Khabibullayev	22040101116	RandomForest, GradientBoosting, ExtraTrees, LSTM, GRU	Veri Entegrasyonu (Merging), Gecikmeli Özelliklerin (Lags) Oluşturulması, GitHub Yönetimi.
Diyorjon Ochilov	22040101139	HistGradientBoosting, AdaBoost	K-Best Özellik Seçimi, Hiper-parametre Optimizasyonu, Model Karşılaştırma Analizleri.
Abdumajid Abdulkhaev	22040101002	XGBoost, SVR	Veri Ölçeklendirme (Scaling), GridSearch Tasarımı, Vize Raporu Taslağı.
İbrahim Halil Yanaç	22040101043	RandomForest, MLPRegressor	MLP Mimari Tasarımı, Performans Görselleştirmeleri (Real vs Pred), Sunum Hazırlığı.
Yesset Yelebayev	22040101123	ElasticNet, SVR	Lasso/ElasticNet Regülerizasyon Analizleri, Literatür Taraması, Veri Sözlüğü Oluşturma.

4) İlgili Çalışmalar (Mini Literatür İncelemesi)

Referans Karşılaştırması

Projemiz hazırlanırken aşağıdaki temel çalışmalar referans alınmış ve karşılaştırılmıştır:

- **Referans 1: McNally et al. (2018):** Bitcoin tahmininde RNN ve LSTM modellerine odaklanmış, %52 civarında yön doğruluğu raporlamıştır. Veri seti sadece teknik verilerle sınırlıdır.
- **Referans 2: Sovbetov (2018):** Kripto paraların makroekonomik faktörlerle (enflasyon, borsa endeksleri) uzun vadeli ilişkisini incelemiştir. Ancak bu çalışma bir tahminleme (prediction) modelinden ziyade istatistiksel bir analizdir.
- **Referans 3: Chen et al. (2020):** Makine öğrenmesi yöntemlerini (XGBoost, RandomForest) Bitcoin için kullanmış, ancak 2022 sonrası yüksek volatilité dönemini kapsamamıştır.

• Projenin Farklılığı ve Doldurduğu Boşluk

Projemiz, literatürdeki çalışmalardan şu yönleriyle ayrılmaktadır:

1. **Hibrit Veri Seti:** Çoğu çalışma ya sadece teknik analiz (fiyat verisi) ya da sadece makro veriye odaklanırken; MacroMinds, FRED üzerinden alınan 17 farklı makroekonomik göstergeyi 73 sütunluk devasa bir teknik veri setiyle birleştirmiştir.
2. **Gecikmeli Özellik (Lag Features) Yaklaşımı:** Fiyat hareketlerinin zamansal bağımlılığını yakalamak için 1, 7 ve 30 günlük geçmiş veriler girdi olarak eklenmiştir.
3. **Yüksek Volatilité Testi:** Modellerimiz, Bitcoin'in en zorlu dönemi olan **2022-2024 (Aylık piyasası ve kriz dönemleri)** verileri üzerinde test edilmiştir. Literatürdeki birçok modelin bu sert piyasa koşullarında başarısız olduğu görülmüş, ancak bizim Ensemble modellerimiz (AdaBoost, RandomForest) bu dönemde bile 1-7 günlük tahminlerde vize sonuçlarını %20 oranında iyileştirerek yüksek direnç göstermiştir.

5) Veri Tanımı ve Yönetimi

- **Veri Seti**

- **Ad:** MacroMinds Bitcoin & Macroeconomic Database.
- **Kaynak:** Yahoo Finance (Finansal veriler) ve Federal Reserve Economic Data (FRED - Makroekonomik göstergeler).
- **Bağlantı:** [Yahoo Finance BTC-USD](#), [FRED Database](#).
- **Lisans:** Halka açık veriler (Public Domain). Eğitim ve araştırma amaçlı kullanım haklarına sahiptir.

- **Veri Şeması**

- **Değişkenler:** Finansal (Open, Close, High, Low, Volume), Makroekonomik (FEDFUNDS, CPI, DXY, GSPC, VIX, UNRATE, WALCL) ve Teknik İndikatörler (RSI, MACD, SMA).
- **Türler:** Tamamı sayısal (Float64) ve zaman damgalı (Datetime Index).
- **Birimler:** USD (Fiyatlar), Endeks Puanı (DXY, VIX), Yüzde (Faiz/İşsizlik).
- **Beklenen Aralıklar:** BTC Fiyatı (100\$ - 100,000\$), Faiz Oranları (%0 - %6).

- **Boyut**

- **Satır/Sütun:** 4067 satır, 120+ sütun (Gecikmeli özellikler ve teknik indikatörler dahil).
- **Sınıf Dengesi:** Regresyon problemi olduğu için sınıf dengesi yerine "Hedef Değişken Dağılımı" (Target Distribution) dikkate alınmıştır. Fiyat dağılımı sağa çarpıktır (skewed).

- **Veri Erişim Planı:** Veriler Python yfinance ve pandas_datareader kütüphaneleriyle

çekilmiş, merged_with_lags.csv olarak yerel ve Google Drive ortamında depolanmıştır. Güncellemeler API üzerinden manuel tetikleme ile yapılabilmektedir.

- **Etik, Gizlilik, Önyargı:** Veriler tamamen anonim finansal piyasa verileridir; kişisel veri (PII) içermez. **Önyargı:** Finansal kriz dönemleri (2020 Pandemi, 2022 FTX krizi) modellerde sapmaya neden olabilir, bu durum "Outlier" yönetimi ile minimize edilmiştir.

6) Keşifsel Veri Analizi (EDA)

- **Veri Kalitesi Kontrolleri**
 - **Eksiklikler:** Borsa verilerinin kapalı olduğu hafta sonları için BTC'nin 7/24 açık olması nedeniyle oluşan boşluklar `ffill()` yöntemiyle doldurulmuştur.
 - **Sızıntı (Leakage) Riski:** "Gelecek verisinin" özelliklere sızması için tüm kaydırmalar (Shifting) ve gecikmeler (Lags) hedef değişken üzerinden titizlikle yapılmıştır.
 - **Dağılımlar ve Denge:** Histogram analizlerinde BTC fiyatının logaritmik dönüşümünün dağılımı normalleştirdiği görülmüştür. Hedef değişkenlerin zaman içindeki değişimi (Stationarity) incelenmiştir.
 - **Özellik-Hedef İlişkileri:** * **Korelasyon:** BTC ile S&P 500 arasında kuvvetli pozitif (+0.85), BTC ile DXY (Dolar Endeksi) arasında negatif (-0.70) korelasyon saptanmıştır.
 - **Karşılıklı Bilgi (MI):** En yüksek bilgi kazancının gecikmeli (lagged) fiyat özelliklerinden geldiği tespit edilmiştir.
 - **Görselleştirme Planı:** * **Boxplots:** Volatilité ve aykırı değerleri tespit etmek için kullanılmıştır.
 - **Heatmap:** 73+ değişken arasındaki çoklu bağlantı (Multicollinearity) sorununu görmek için korelasyon matrisi çizdirilmiştir.
 - **Time-Series Plot:** Real vs. Predicted karşılaştırması için ana araçtır.
-

7) Veri Hazırlama Planı

- **Temizleme:** Hatalı girilen hacim verileri ve tarih çakışmaları temizlenmiş, birimler USD ve standart yüzdelik formatına getirilmiştir.
- **İmputasyon Stratejisi:** Zaman serisi doğasına uygun olarak forward fill (son bilinen değerlerin taşınması) tercih edilmiştir; ortalama/medyan ataması zaman sırasını bozacağı için kaçınılmıştır.
- **Dönüşümler**
 - **Ölçeklendirme:** Deep Learning (LSTM, GRU) ve SVR modelleri için MinMaxScaler (0-1 arası), Ensemble modeller için StandardScaler kullanılmıştır.

- **Log Transform:** Fiyat değişimlerini normalize etmek için logaritmik getiri hesaplamaları yapılmıştır.
- **Özellik Mühendisliği:**
 - **Zaman Aralığı Özellikleri:** Final aşamasının kalbi olan Target_1d_lag, Target_7d_lag, Target_30d_lag özellikleri üretilmiştir.
 - **Teknik Analiz:** RSI, MACD ve Hareketli Ortalamalar (Moving Averages) etki alanı özellikleri olarak eklenmiştir.
- **Özellik Seçimi ve Boyut İndirgeme:**
 - **Filter:** Mutual Information (Karşılıklı Bilgi) kullanılarak en değerli 30-50-120 özellik seçilmiştir.
 - **Boyut İndirgeme:** PCA (Temel Bileşen Analizi) kullanılarak 73+ boyutlu veri seti, varyansın %95'ini temsil eden 10-20 bileşene indirilerek modeller test edilmiştir.
 - **Wrapper:** RFE (Recursive Feature Elimination) yöntemiyle modellerin performansını en çok artıran alt kümeler belirlenmiştir.

8) Modelleme Planı

- **Baseline Model:** Final aşamasında, gelişmiş modellerin başarısını ölçmek için "**Naive Baseline**" (**Kalıcı Tahmin**) yaklaşımı kullanılmıştır. Bu model, bir sonraki günün fiyatının bugünkü fiyatla aynı olacağını varsayar. Gelişmiş modellerimizin başarısı, bu basit varsayımın ve eğitim setinin ortalamasının (Mean Baseline) ne kadar üzerine çıktığıyla değerlendirilmiştir.
- **Aday Modeller:** Projenin final safhasında, Bitcoin'in karmaşık ve lineer olmayan yapısını çözmek için 3 ana model ailesi seçilmiştir:
 - **Ensemble Learning (Topluluk Öğrenmesi):** **XGBoost, RandomForest, AdaBoost, HistGradientBoosting ve ExtraTrees.** *Neden:* Karar ağacı tabanlı bu modeller, finansal verilerdeki gürültüye karşı dirençlidir ve özellikler arasındaki karmaşık etkileşimleri yakalamada yüksek performans gösterir.
 - *Geliştiriciler:* **Abdumajid** (XGBoost), **İbrahim & Khaiitmurad** (RandomForest), **Diyorjon** (AdaBoost, HistGB).

- **Deep Learning (Derin Öğrenme): LSTM (Long Short-Term Memory) ve GRU.**
Neden: Zaman serisi verilerindeki uzun vadeli bağımlılıkları ve ardışık kalıpları bellek hücreleri sayesinde öğrenebilirler.
 - *Geliştirici:* Khaiitmurod.
 - **Neural Networks & Support Vector: MLPRegressor ve SVR.** *Neden:* Çok katmanlı algılayıcılar (MLP) ve SVR, yüksek boyutlu özellik uzayında (112-119 özellik) esnek çözümler sunar.
 - *Geliştiriciler:* İbrahim (MLP), Abdumajid & Yesset (SVR).
 - **Hiper-Parametre Ayarlama:** Modellerin aşırı öğrenmesini (overfitting) engellemek ve en iyi kapasiteye ulaşmak için **RandomizedSearchCV** ve **GridSearchCV** stratejileri uygulanmıştır.
 - *Parametre Aralıkları:* `n_estimators` (50-600), `learning_rate` (0.01-0.1), `max_depth` (3-10), `subsample` (0.7-0.9) ve sinir ağları için `hidden_layer_sizes`.
 - *Erken Durdurma:* LSTM ve Gradient Boosting modellerinde doğrulama kaybı (validation loss) iyileşmediğinde eğitim durdurulmuştur.
 - **Sınıf Dengesizliği Stratejisi:** Proje bir **Regresyon** görevi olduğu için klasik sınıf dengesizliği (SMOTE vb.) uygulanmamıştır. Ancak Bitcoin fiyatının sağa çarpık (skewed) dağılımını dengelemek için veriler **StandardScaler** ve **MinMaxScaler** ile ölçeklendirilmiş; hedef değişkenin 2022 sonrası aşırı oynaklığına karşı **MAPE** metriği ile oransal hata analizi yapılmıştır.
-

9) Değerlendirme Tasarımı (Final Aşaması)

- **Kullanılan Metrikler:** Modellerin performansı, finansal tahmin standartlarına uygun olarak şu dört metrikle ölçülmüştür:
 - **R² (Belirleme Katsayısı):** Modelin varyansı açıklama gücü (Hedef: 1.0'a yakınlık).
 - **RMSE (Root Mean Squared Error):** Büyük hataların büyüklüğünü ölçmek için.
 - **MAE (Mean Absolute Error):** Ortalama mutlak hata payı.
 - **MAPE (%) (Mean Absolute Percentage Error):** Tahminin gerçek fiyata göre yüzdesel sapması (Yatırımcı kararları için en kritik metrik).

- **Doğrulama (Validation) Protokolü:** Veri sızıntısını (Data Leakage) önlemek için **Zaman Serisi Bazlı Bölme (Time-Series Split)** uygulanmıştır.
 - **Eğitim (Train):** 2022-01-01 öncesi veriler (Modelin öğrenme safhası).
 - **Test:** 2022-01-01 ve sonrası (Piyasanın en sert düşüş ve yükselişlerini içerir).
 - Bu yöntemle, modelin geçmiş veriyi kullanarak geleceği görmesi engellenmiş, gerçek dünya senaryosu simüle edilmiştir.
 - **Hata Analizi:** Her hedef (Target_1d, 7d, 30d, 365d) için **Gerçek Fiyat vs. Tahmin (Real vs Pred)** grafik analizi yapılmıştır. Modellerin özellikle ani düşüş dönemlerindeki (2022 Ayı Piyasası) tepkileri ve gecikme (lag) yapıp yapmadıkları bu grafikler üzerinden incelenmiştir.
-

10) Riskler ve Azaltma Yöntemleri

- **Veri Riskleri:** Bitcoin fiyatının "Stationary" olmaması (durağan olmaması) ve 2022 sonrası test setindeki yüksek volatilité.
 - **Azaltma:** Girdi olarak 17 farklı makroekonomik verinin ve fiyata dair **gecikmeli özelliklerin (Lag Features)** eklenmesiyle modelin piyasa koşullarına uyumu artırılmıştır.
 - **Yöntem Riskleri:** Özellikle derin öğrenme (LSTM/GRU) modellerinde kısıtlı veriyle **Overfitting** riski.
 - **Azaltma:** Dropout katmanları eklenmiş ve hiper-parametre araması sırasında karmaşıklık kısıtlanmıştır (max_depth vb.).
 - **Covariate Shift:** Piyasa dinamiklerinin (boğa vs ayı sezonu) değişmesiyle modelin başarısının düşmesi.
 - **Azaltma:** Model başarısı sadece tek bir gün için değil, 4 farklı zaman ufku (1, 7, 30, 365 gün) üzerinden test edilerek genel başarısı doğrulanmıştır.
-

11) Kullanılan Araçlar

- **Environment:** Python 3.10+, Google Colab (T4 GPU desteği).
- **Kütüphaneler:**
 - *Model:** scikit-learn, XGBoost, TensorFlow, Keras.
 - *Veri:* pandas, numpy, pandas_datareader.
 - *Görselleştirme:* matplotlib, seaborn.
- **Random Seeds:** Sonuçların tekrarlanabilirliği için tüm süreçte random_state=42 sabitlenmiştir.
- **Geliştirilen Kodlar:** Tüm ileri seviye modellemeler ve sonuçlar ekibin GitHub reposunda mevcuttur: <https://github.com/murat-khabibullayev/Bitcoin-Price-Prediction-Mining>
- **Beklenen Çalışma Süresi:** En karmaşık LSTM ve Ensemble tuning süreçleri, donanım kısıtlamaları dahilinde her hedef için yaklaşık 30-45 dakikalık bir hesaplama süresinde tamamlanmıştır.

12) Beklenen Sonuçlar ve Görselleştirme Planı






Bu bölümde, projenin final aşamasında geliştirilen gelişmiş modellerin (Advanced Models) performansı, hata dökümleri ve model kararlarının arkasındaki nedenler analiz edilmiştir.

Metrik ve Performans Tabloları

Ekip üyelerinin farklı zaman ufukları (Target_1d, 7d, 30d, 365d) için elde ettiği en iyi sonuçlar aşağıda konsolide edilmiştir. 2022 sonrası "Test Seti" verilerine göre elde edilen bu sonuçlar, vize dönemindeki temel modellere kıyasla %20-30 oranında iyileşme göstermiştir.

1. Khaiitmurod Khabibullayev Sonuçları


Target	Model	RMSE	MAE	R2	MAPE (%)
Target_1d	RandomForest	2,268.99	1,612.70	0.9828	3.61%
Target_1d	GradientBoosting	2,948.23	1,867.26	0.9710	3.61%
Target_1d	ExtraTrees	4,861.93	3,894.55	0.9212	8.35%
Target_1d	LSTM	26,687.66	23,579.44	-1.4597	49.48%
Target_1d	GRU	26,723.21	21,572.19	-1.4662	40.94%
Target_30d	RandomForest	16,817.75	12,489.25	0.2258	22.73%
Target_30d	GradientBoosting	18,893.08	14,317.26	0.0229	26.39%
Target_30d	ExtraTrees	25,349.68	19,645.96	-0.7591	34.93%
Target_365d	GradientBoosting	43,329.55	36,749.37	-2.6001	39.36%
Target_365d	RandomForest	43,968.02	37,574.42	-2.7070	40.41%
Target_365d	ExtraTrees	52,278.00	46,253.81	-4.2407	51.00%
Target_7d	RandomForest	7,334.32	6,022.05	0.8225	13.13%
Target_7d	GradientBoosting	8,973.33	6,618.10	0.7342	12.59%
Target_7d	ExtraTrees	11,497.30	10,023.75	0.5637	21.70%




2. Abdumajid Abdul Khaev Sonuçları

Target	Model	RMSE	MAE	R2	MAPE (%)
Target_1d	XGBoost	6,982.27	5,303.07	0.8375	10.34%
Target_1d	SVR	36,440.41	31,953.36	-3.4253	67.99%
Target_7d	XGBoost	11,927.14	10,561.70	0.5305	23.60%
Target_7d	SVR	36,886.60	32,418.44	-3.4908	68.33%
Target_30d	XGBoost	23,172.26	18,006.11	-0.4699	33.17%
Target_30d	SVR	39,835.32	34,853.12	-3.3439	69.69%
Target_365d	XGBoost	53,441.54	48,283.41	-4.4766	54.24%
Target_365d	SVR	69,481.67	65,540.72	-8.2574	76.61%


Hata Karşılaştırması (RMSE)
(Daha Düşük Daha İyi)




Başarı Skoru Karşılaştırması (R2)
(1.0'a Yakın Olan Daha İyi)




Son 100 Gün Detaylı Performans İncelemesi
(Target_1d - XGBoost)




Target_7d - XGBoost (R2: 0.53)






3. Yesset Yelebayev Sonuçları

Target	Model	RMSE	MAE	R2	MAPE (%)
Target_1d	ElasticNet	33,486.75	27,381.14	-2.7370	N/A
Target_1d	SVR	39,480.03	35,476.83	-4.1944	N/A
Target_7d	ElasticNet	33,958.89	27,748.35	-2.8062	N/A
Target_7d	SVR	39,969.74	35,980.57	-4.2729	N/A
Target_30d	ElasticNet	36,832.89	30,030.58	-2.7138	N/A
Target_30d	SVR	42,708.13	38,178.61	-3.9930	N/A
Target_365d	ElasticNet	70,102.55	65,686.65	-8.4236	N/A
Target_365d	SVR	74,867.96	71,180.59	-9.7484	N/A









4. Diyorjon Ochilov Sonuçları

Target	Model	RMSE	MAE	R2	MAPE (%)
Target_1d	HistGradientBoosting	3,027.37	1,997.00	0.9719	4.28%
Target_1d	AdaBoost	2,948.48	2,074.10	0.9734	4.75%
Target_7d	HistGradientBoosting	6,875.36	5,639.70	0.8570	13.40%
Target_7d	AdaBoost	5,793.49	4,299.66	0.8985	9.68%
Target_30d	HistGradientBoosting	16,510.67	13,484.00	0.2994	29.12%
Target_30d	AdaBoost	15,584.80	11,808.19	0.3758	23.11%
Target_365d	HistGradientBoosting	62,184.15	56,571.17	-5.4151	66.29%
Target_365d	AdaBoost	59,105.11	54,888.60	-4.7955	65.73%

5. İbrahim Halil Yanaç Sonuçları

Target	Model	RMSE	MAE	R2	MAPE (%)
Target_1d	RandomForest	2,425.06	1,685.21	0.9804	3.69%
Target_7d	RandomForest	6,975.87	5,572.41	0.8394	11.94%
Target_30d	RandomForest	17,302.59	13,346.62	0.1805	25.70%
Target_365d	RandomForest	45,260.42	39,199.66	-2.9281	42.56%
Target_1d	MLPRegressor	29,680.37	22,948.50	-1.9358	42.72%
Target_7d	MLPRegressor	40,167.56	33,936.26	-4.3252	68.55%
Target_30d	MLPRegressor	32,745.01	24,551.42	-1.9352	41.90%
Target_365d	MLPRegressor	46,703.86	37,283.91	-3.1827	38.57%



En İyi Model Karşılaştırması (MacroMinds Şampiyonları)

Hedef Süresi	Kazanan Öğrenci	En İyi Model	R ² Skoru	MAPE (%)
1 Gün	Khaiitmurod	RandomForest	0.9828	3.61%
7 Gün	Diyorjon	AdaBoost	0.8984	9.67%
30 Gün	Diyorjon	AdaBoost	0.3757	23.11%
365 Gün	Khaiitmurod	GradientBoosting	-2.60	39.36%

12) Sonuçların Değerlendirilmesi ve Karşılaştırmalı Analiz

Bu bölümde, MacroMinds ekibi tarafından geliştirilen 10'dan fazla gelişmiş modelin performansı; kısa, orta ve uzun vadeli tahmin ufukları bazında analiz edilmiştir.

12.1. Model Ailelerinin Performans Karşılaştırması

Final aşamasında test edilen modelleri üç ana grupta topladığımızda şu sonuçlara ulaşılmıştır:

1. Topluluk Öğrenme (Ensemble Learning) Modelleri:

- **RandomForest, AdaBoost ve XGBoost** modelleri projenin en başarılı modelleri olmuştur.
- Özellikle **Khaiitmurod** ve **İbrahim** tarafından eğitilen RandomForest modelleri, 1 günlük tahminlerde **%98** üzerinde R² skoru yakalamıştır.
- **Neden:** Bu modeller, Bitcoin verisindeki aykırı değerlere (outliers) karşı dirençlidir ve makroekonomik değişkenler ile fiyat arasındaki doğrusal olmayan ilişkileri başarıyla haritalandırmıştır.

2. Derin Öğrenme (Deep Learning) Modelleri:

- **LSTM ve GRU** modelleri, teorik olarak zaman serilerinde güçlü olsalar da, bu projedeki veri setinde RandomForest kadar yüksek başarı gösterememiştir.
- **Neden:** Derin öğrenme modelleri çok daha fazla veriye ihtiyaç duyar. 4000 satırlık veri seti, RandomForest gibi ağaç tabanlı modeller için idealken, LSTM'in tam kapasite öğrenmesi için yetersiz kalmış olabilir.

3. Doğrusal ve Destek Vektör Modelleri:

- **ElasticNet ve SVR** modelleri, özellikle 2022 sonrası yüksek volatilité döneminde (test seti) negatif R^2 değerleri vererek beklentinin altında kalmıştır.
- **Neden:** Bitcoin fiyatı durağan (stationary) değildir ve doğrusal modeller bu sert fiyat dalgalanmalarını yakalamakta yetersiz kalmaktadır.

12.2. Zaman Ufkuna Göre Başarı Analizi

Modellerin başarısı, tahmin süresi uzadıkça dramatik bir değişim göstermektedir:

- **Kısa Vade (1-7 Gün):** Modeller mükemmel yakın sonuçlar vermiştir. Bunun temel nedeni, "Gecikmeli Özelliklerin" (Lag Features) kısa vadeli trendi çok iyi temsil etmesidir. **Diyorjon'un AdaBoost** modeli 7 günlük tahminde **%89.84** R^2 ile haftalık bazda en güvenilir model olmuştur.
- **Orta Vade (30 Gün):** Başarı oranı %37 seviyelerine (Diyorjon - AdaBoost) gerilemiştir. Bu durum, Bitcoin fiyatının 1 aydan sonra teknik verilerden ziyade dışsal şoklara (FED faiz kararları, savaşlar vb.) daha duyarlı hale geldiğini kanıtlar.
- **Uzun Vade (365 Gün):** Tüm modeller negatif R^2 vermiştir. 1 yıl sonrası için yapılan tahminlerin hata payı (RMSE) çok yüksektir. Bu, Bitcoin'in uzun vadeli projeksiyonunun mevcut makro verilerle "regresyon" üzerinden yapılmasının zorluğunu göstermektedir.

12.3. Yorumlanabilirlik ve Öznitelik Önemi (Feature Importance)

Modellerin hangi verilere güvenerek tahmin yaptığını analiz ettiğimizde şu bulgulara ulaşıldı:

- **En Güçlü Girdi:** Tahmin edilen günden bir önceki günün fiyatı (Target_lag1) en yüksek ağırlığa sahiptir.
- **Makroekonomik Etki: DXY (Dolar Endeksi) ve S&P 500** verileri, model kararlarında en etkili dışsal faktörler olmuştur. Doların güçlendiği dönemlerde modellerin Bitcoin fiyatında düşüş eğilimi öngördüğü saptanmıştır.

- **Volatilite Etkisi: VIX (Korku Endeksi)** verisi, özellikle ani düşüşlerin (crash) tahmin edilmesinde modeller için kritik bir sinyal görevi görmüştür.
-

12.4. Genel Sonuç ve Öneriler

Final projesi çalışmaları sonucunda; Bitcoin fiyat tahmini için **Ensemble Learning** yöntemlerinin, makroekonomik verilerle birleştğinde kısa vadeli (1-7 gün) yüksek doğruluklu sonuçlar ürettiği kanıtlanmıştır.

13) Referanslar

[1] Yahoo Finance, "Bitcoin USD (BTC-USD) Historical Data," 2024. [Online]. Available: <https://finance.yahoo.com/quote/BTC-USD/>

[2] Federal Reserve Economic Data (FRED), "Economic Indicators for Bitcoin Analysis (FEDFUNDS, CPI, DXY, VIX)," St. Louis Fed, 2024. [Online]. Available: <https://fred.stlouisfed.org/>

[3] S. McNally, J. Roche, and S. Caton, "Predicting the price of Bitcoin using Machine Learning," *2018 26th Euromicro International Conference on Parallel, Distributed and Network-based Processing (PDP)*, Cambridge, UK, 2018, pp. 339-343.

[4] Y. Sovbetov, "Factors Influencing Cryptocurrency Prices: Evidence from Bitcoin, Ethereum, Dash, Litecoin, and Monero," *Journal of Economics and Financial Analysis*, vol. 2, no. 2, pp. 1-27, 2018.

[5] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.

[6] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, CA, USA, 2016, pp. 785–794.